


Методы обучения без учителя используются, когда **нет размеченных данных** и невозможно использовать подходы обучения с учителем.

К обучению без учителя можно отнести:

- **Методы кластеризации.** Они позволяют разделить объекты на группы, внутри которых объекты максимально похожи друг на друга.
- **Методы понижения размерности.** С их помощью можно уменьшить число признаков, которые характеризуют объект. Обычно количество признаков уменьшают до двух-трёх для дальнейшей визуализации данных или использования при обучении моделей.
- **Методы ассоциации.** Они используются для того, чтобы найти правила и законы, по которым существует последовательность действий.

Кластеризация позволяет разбить объекты на группы, которые называются **кластерами**.

Например, на картинке ниже изображены разные кластеры еды и напитков:




Похожие объекты оказываются внутри одного кластера. Если же объекты разные, то они должны оказаться в разных кластерах.

Данная задача не сводится к задаче классификации, так как в данном случае нет правильных ответов о том, как разделить данные.

Также у каждого кластера есть центроид.

Центроид — это центр масс кластера, или среднее значение координат объектов кластера.

На рисунке ниже изображено три кластера, крестик в каждом из них — это центроид:



Кластеризация k-means

Идея алгоритма состоит в том, что он разбивает множество элементов векторного пространства на заранее заданное пользователем число кластеров, а далее стремится минимизировать суммарное квадратичное отклонение объектов внутри кластера до центроида кластера.

Математически это выглядит следующим образом:

$$V = \sum_{i=1}^k \sum_{x \in S_i} (x - \mu_i)^2$$

Мы итерируемся по каждому кластеру и для всех векторов x внутри кластера S_i подсчитываем центроиды (μ_i). Далее рассчитываем разницу между каждым вектором x кластера S_i и центроидом кластера S_i . Необходимо, чтобы это значение, возведённое в квадрат (V), было минимальным для каждого кластера.

Вариации алгоритма k-means:

Название	Принцип работы	Подробности
k-means	Находит центроиды кластера как среднее значение координат.	Документация (init='random')
k-means++	В классическом алгоритме k-means центроиды выбираются случайно, но это может приводить к тому, что два объекта, которые находятся близко друг к другу, будут центроидами двух разных кластеров — это будет приводить к долгой работе алгоритма. Алгоритм k-means++ чуть «хитрее» и выбирает центроиды кластеров не совсем случайно.	Документация (init='k-means++'; по умолчанию в sklearn при запуске k-means используется алгоритм k-means++)
k-medians	На этапе поиска центроидов кластера находит не среднее значение координат, а медиану.	Документация
k-medoids	Работает так же, как k-medians, но медианой кластера будет не какая-то точка в кластере, а объект, который находится ближе всего к этим координатам медианы кластера.	Документация
fuzzy c-means	Данный алгоритм разрешает нечётко присваивать кластеры. Каждый объект может принадлежать к разным кластерам с разной вероятностью.	Документация

Способы выбора оптимального количества кластеров:

1. Метод локтя.

Чтобы определить оптимальное количество кластеров, используя метод локтя, необходимо нарисовать график, на котором по оси x будет отложено количество кластеров, а по оси y — инерция.


Инерция — это сумма квадратов расстояний объектов датасета до центра масс ближайшего к ним кластера.

The diagram shows the formula for inertia with several annotations:

- An arrow points from the text "количество кластеров" to the variable k in the outer summation.
- An arrow points from the text "количество объектов кластера" to the variable n in the inner summation.
- An arrow points from the text " i -ый объект j -го кластера" to the variable x_i^j in the distance term.
- An arrow points from the text "центроид j -го кластера" to the variable c_j in the distance term.
- A bracket under the distance term $||x_i^j - c_j||$ is labeled "расстояние".

$$\sum_{j=1}^k \sum_{i=1}^n ||x_i^j - c_j||^2$$


Когда инерция быстро снижается, область считается **недообученной**, а далее, после «перегиба», идёт очень медленное снижение инерции, и область считается **переобученной**.



2. Коэффициент силуэта.

График силуэта, в отличие от графика локтя, имеет пиковый характер, поэтому его проще визуализировать и анализировать.

На графике ниже по оси x отложено количество кластеров, а по оси y — значение коэффициента силуэта. Можно отчётливо увидеть, что пик графика приходится на количество кластеров, равное 3:



Метрики для оценки качества проведённой кластеризации

Метрика	Интерпретация и применение	Диапазон значений	Функция в модуле metrics библиотеки sklearn
Однородность (homogeneity score)	Показывает, насколько однородны получившиеся кластеры. Если в кластере оказались элементы из другого кластера, значение метрики уменьшается.	1 — идеально однородные кластеры; 0 — кластеры максимально разнородные.	<code>homogeneity_score</code>
Полнота (completeness score)	Показывает, насколько кластер заполнен объектами, которые в действительности должны принадлежать к этому кластеру.	1 — идеальное значение; 0 — объекты, которые должны образовывать один кластер, разделились на большее количество кластеров.	<code>completeness_score</code>
V-мера (V-measure)	Комбинация метрик полноты и однородности кластеров.	1 — идеально полные и однородные кластеры; 0 — полученные кластеры неоднородные, количество кластеров	<code>v_measure_score</code>

		слишком большое.	
Индекс Рэнда	Показывает долю объектов датасета, которые мы правильно определили в кластер.	1 — все объекты в предсказанном кластере попали в правильные кластеры.	rand_score


Иерархическая кластеризация

Принцип иерархической кластеризации основан на построении дерева (иерархии) вложенных кластеров.

При иерархической кластеризации строится **дендрограмма**.

Дендрограмма — это древовидная диаграмма, которая содержит уровней. Каждый уровень — это шаг укрупнения кластеров.


Чем больше схожесть между двумя объектами на дендрограмме, тем ниже высота внутренней ветки, которая идёт из объекта или кластера:



Используя иерархическую кластеризацию, кластеры можно создавать **двумя методами**:


1. Агломеративный метод (agglomerative).

Новые кластеры создаются в ходе объединения более мелких кластеров:



2. Дивизионный (дивизивный) метод (divisive).

Кластеры создаются при делении крупных кластеров:



Преимущества и недостатки иерархической кластеризации:

- ✓ Можно построить дендрограмму и понять, как устроены данные.
- ✓ Работает на небольшом датасете.

- ✗ Необходимость выбора оптимального количества кластеров.
- ✗ Если данных много, дендрограмма становится большой и сложной для понимания.
- ✗ Может неравномерно разделять данные на кластеры.

ЕМ-алгоритмы кластеризации

В основе данного подхода лежит предположение, что любой объект принадлежит ко всем кластерам, но с разной вероятностью.


Один из примеров ЕМ (Expectation-maximization)-алгоритма — это k-means-кластеризация, рассмотренная ранее.

Алгоритм состоит из **двух шагов**. Если рассмотреть их на примере k-means, то:

- на шаге **Е** мы вычисляем, к какому кластеру будет относиться объект на основании расстояний до центроида;
- на шаге **М** мы пересчитываем центроиды кластеров.

Преимущества и недостатки ЕМ-кластеризации:


- ✓ Кластеры, которые находит этот алгоритм, могут принимать форму эллипса, а не ограничиваться окружностями. K-Means является частным случаем GMM.



- ✓ Если объект находится в середине двух перекрывающихся кластеров, то, в отличие от k-means, не

- ✗ Нужно задавать количество кластеров.
- ✗ Чувствителен к тому, с какой точки начинается алгоритм.
- ✗ Может медленно сходиться, т. е. искать, как оптимально описать кластеры.

нужно решать, к какому кластеру он принадлежит: объект может принадлежать к двум разным кластерам с разной вероятностью.



Спектральная кластеризация


Данный тип кластеризации использует собственные значения (спектр) матрицы сходства данных, чтобы снизить размерность данных и далее провести кластеризацию.

Преимущества и недостатки спектральной кластеризации:

- ✓ Подходит для кластеризации данных с большим количеством признаков, так как использует технику понижения размерности.
- ✓ Эффективна для кластеризации разреженных данных.
- ✓ Хорошо работает на практически любых распределениях данных. На рисунке ниже представлены

- ✗ Нужно заранее задавать количество кластеров.
- ✗ Подходит для задач сбалансированной классификации, то есть количество точек между кластерами не сильно отличается.

результаты кластеризации
данных с разным
распределением признаков.



Алгоритм показал хорошие результаты во всех случаях, за исключением данных в форме вытянутого эллипса (столбец 3).

Кластеризация на основе плотности

Такая кластеризация находит в датасете области с высокой плотностью и на их основе образует кластеры. Редкие объекты, которые находятся в отдалении от других данных и для которых нужен отдельный кластер, считаются **шумом**.

Наиболее популярный алгоритм кластеризации на основе плотности — **DBSCAN**.

Преимущества и недостатки DBSCAN:

- ✓ Не нужно задавать количество кластеров.
- ✓ Устойчив к шуму и выбросам, может находить выбросы в данных.
- ✓ Способен найти кластеры любой геометрической формы.

- ✗ Не может качественно кластеризовать наборы данных с большой разницей в плотности.
- ✗ Равноудалённые от двух кластеров объекты могут быть отнесены к тому кластеру, с которого алгоритм начал работать, что не всегда

оказывается верным.

✗ Бывает сложно подобрать `eps`.


Основная информация по разным видам кластеризации:

Алгоритм	Принцип работы	Преимущества	Недостатки
Иерархическая кластеризация	Строит дерево (иерархию) вложенных кластеров.	✓ позволяет построить дендрограмму кластеризации и тем самым лучше проанализировать данные; ✓ позволяет найти иерархию в данных.	✗ необходимо выбирать оптимальное количество кластеров; ✗ неравномерное распределение кластеров; ✗ работает на небольшом датасете.
ЕМ-кластеризация (модель гауссовой смеси)	Предполагает, что любое наблюдение принадлежит ко всем кластерам, но с разной вероятностью.	✓ хорошо работает на данных в форме эллипса, окружности, на перекрывающихся данных; ✓ устойчив к шуму в данных; ✓ работает быстро при удачном выборе начальных	✗ необходимо выбирать оптимальное количество кластеров; ✗ работает долго при неудачном выборе кластеров.




		кластеров.	
Спектральная кластеризация	Снижает размерность данных, а затем применяет более простые алгоритмы кластеризации, например k-means).	✓ подходит для кластеризации данных с большим количеством признаков; ✓ эффективен для кластеризации разрежённых данных; ✓ хорошо работает на практически любых распределениях данных.	✗ необходимо выбирать оптимальное количество кластеров; ✗ подходит для задач сбалансированной классификации, то есть количество точек между кластерами не сильно отличается.
Кластеризация на основе плотности	Находит в датасете области с высокой плотностью и, основываясь на этом, образует кластеры.	✓ нет необходимости выбирать оптимальное количество кластеров; ✓ устойчив к шуму и выбросам.	✗ не способен качественно кластеризовать наборы данных с большой разницей в плотности; ✗ иногда бывает сложно подобрать параметры для моделирования.



Визуализировать результаты кластеризации можно с помощью:

- диаграммы рассеяния для двухмерного и трёхмерного случаев;
- Convex Hull, или выпуклой оболочки;
- Clustergram;
- дендрограммы.



Способ визуализации	Графическое представление	Кластеризация	Цели визуализации
2D-визуализация (Диаграмма рассеяния)		Любые алгоритмы кластеризации, отработавшие на двухмерном пространстве признаков.	Быстро визуально оценить результаты кластеризации.

2D-визуализация (Convex Hull)		Любые алгоритмы кластеризации, отработавшие на двухмерном пространстве признаков.	Понять размеры получившихся кластеров, оценить количество выбросов в кластерах и похожесть объектов внутри кластера.
2D-визуализация (Дендрограмма)		Иерархическая кластеризация на двухмерном пространстве признаков.	Визуализировать, как датасет делился на кластеры, оценить схожесть кластеров. С помощью дендрограммы можно оценивать, какое количество кластеров будет оптимальным.
2D-визуализация (Clustergram)		K-means, GMM и иерархическая кластеризация. Применима для n-мерного пространства признаков.	Понять, как датасет делится на различное количество кластеров, оценить, насколько равномерные кластеры были образованы.

3D-визуализация (Matplotlib)		Любые алгоритмы кластеризации, отработавшие на трёхмерном пространстве признаков.	Быстро визуально оценить результаты кластеризации.
3D-визуализация (Plotly)		Любые алгоритмы кластеризации, отработавшие на трёхмерном пространстве признаков.	Быстро визуально оценить результаты кластеризации в интерактивном режиме.

Понижение размерности

Иногда работа с многомерным пространством вызывает трудности. Они могут возникнуть, если:

- ➔ нужно визуализировать результаты кластеризации, а пространство признаков многомерное.
- ➔ нужно обучить модель, а объект описывается большим количеством признаков. Эти признаки могут быть избыточными или малоинформативными, что приведёт к плохим результатам при обучении модели.
- ➔ Объекты обычно не описываются двумя-тремя признаками, и датасеты бывают большими, поэтому на построение модели может уходить много времени.

Избежать этих проблем поможет снижение размерности данных.

Задача снижения размерности — это задача преобразования данных с целью уменьшения количества признаков, которые описывают объект.

Как вы можете догадаться, при уменьшении количества признаков мы теряем часть информации. Например, на изображении ниже Губка Боб после уменьшения размерности стал описываться меньшим количеством признаков и поэтому стал выглядеть по-другому.

До уменьшения размерности:



После:



Методы снижения размерности могут преобразовывать данные двумя способами:

- линейно,
- нелинейно.

PCA

Для уменьшения размерности **метод главных компонент (Principal Components Analysis, PCA)** проводит линейное преобразование пространства, которое сохраняет длины векторов. Таким образом происходит отображение признаков в новое пространство с меньшей размерностью.

В новом пространстве появляются новые оси. Они строятся таким образом, что для первой оси дисперсия данных должна быть максимальной, а вторая ось ортогональна первой и имеет максимально возможную дисперсию.

Первой главной компонентой будет называться первая ось в новом пространстве.

РСА часто используют для увеличения скорости обучения модели: данный метод действительно позволяет уменьшить время обучения модели, при этом существенно не изменив её качество.

t-SNE

Для того чтобы визуализировать многомерное пространство признаков, необходимо уменьшить его размерность до двухмерного или трёхмерного. В этом поможет **t-SNE (t-distributed Stochastic Neighbor Embedding)**, что переводится с английского как «стохастическое вложение соседей с t-распределением».

t-SNE, в отличие от PCA, использует технику нелинейного снижения размерности данных. Обычно используется снижение размерности многомерного пространства до двух- или трёхмерного с целью дальнейшей визуализации. При преобразовании похожие объекты оказываются рядом, а непохожие — далеко друг от друга.

	PCA	t-SNE
Преобразование, которое используется для снижения размерности	Линейное	Нелинейное
Кейсы использования	Уменьшение размерности данных с	Визуализация многомерного

	целью их дальнейшего использования в ML-моделях	пространства
Вызов в sklearn	<code>from sklearn.decomposition import PCA</code>	<code>from sklearn.manifold import TSNE</code>